

התפתחות מנגנוני תיאום כלים מרובים בסוכני LLM

אבי איילי — ת.ז. 300228160
קורס: אורקסטרציה של סוכני AI
מרצה: ד"ר יורם סגל
2026

מסמך זה נוצר בסיוע בינה מלאכותית

תוכן העניינים

3	1 הקדמה והקשר היסטורי
3	1.1 בקרת הקשר ומודלים בגדול
4	2 ארכיטקטורה וטפוזי עיצוב
4	2.1 מנגנון תשומת הלב ותפקידו בעיבוד שפה
4	2.2 דיזיין של מערכות הקשר
4	2.3 רשתות נוירונים עמוקות ומודלים יסודיים
6	3 ניהול מצב ודו-כיווניות טקסט
6	3.1 מנגנוני ניהול מצב בעבודה עם מודלים
6	3.2 דו-כיווניות בעיבוד טקסט
8	4 פרוטוקול בקרת המודל
8	4.1 אינטרפייס של Model Context Protocol
8	4.2 טכניקות שדרוג קשר
8	4.3 ביטחון וערכיות בשדרוג קשר
01	5 איומים וחולשות
01	5.1 סוגי איומים על מודלים של שפה
01	5.2 איומים על פרוטוקול בקרת המודל
01	5.3 אתגרים של קנה מידה
11	6 הפחתת סיכונים וכיווניות עתידית
11	6.1 אסטרטגיות הפחתת סיכונים
11	6.2 תקנון וחקיקה
21	6.3 כיווניות עתידית ומחקר פתוח
31	נספח א': מילון מונחים

תקציר

מחקר זה עוסק בהתפתחות מנגנוני תיאום כלים מרובים בסוכני LLM. בעשור האחרון הפכו מודלי שפה למרכיב מרכזי במערכות בינה מלאכותית, ועלה הצורך לתאם ביניהם לבין כלים חיצוניים כגון מנועי חיפוש, מחשבוניס ובסיסי נתונים. המחקר בוחן שלוש גישות עיקריות: שיטות היוריסטיות מבוססות-דמיון; מסגרות למידה מפוקחת כגון Toolformer ו-AvaTaR; וארכיטקטורות רב-סוכניות. בנוסף נבחן Model Context Protocol (MCP) כתקן פתוח לממשק כלים. הממצאים מצביעים כי מסגרות המשלבות לולאות חשיבה-פעולה (ReAct, Reflexion) עם תכנון מודע-תלויות (DEPS) משפרות משמעותית את יכולת ההרחבה, הביצועים והתחזוקה של מערכות סוכנים ייצורניות.

פרק 1

הקדמה והקשר היסטורי

תחום הבינה המלאכותית חווה שינוי דרמטי בשנים האחרונות, הנובע בעיקר מהתפתחות בחקר למידה עמוקה ומודלים של שפה טבעית. הרקע ההיסטורי של תחום זה מסתמך על מחקר שנתגבש לאורך עשרות שנים, החל מתרגיל הודעה שנוצר בשנות החמישים של המאה העשרים. בעבר, מערכות בינה מלאכותית היו מבוססות על כללים מפורשים שהתחזקו על ידי מומחים אנושיים. אולם, עם העלייה של שיטות למידה ממוכנת, באופן הדרגתי יותר ויותר מערכות החלו ללמוד דפוסים מהנתונים ישירות. המהלך הזה הכניס חידוש עמוק בדרך בה מחשבים מעבדים מידע טבעי, במיוחד בהקשר של שפות אנושיות. עם הופעתם של מודלים כמו Transformer, תחום עיבוד השפה הטבעית (NLP) עבר מהפכה. מנגנון תשומת הלב (attention mechanism) המשמש בגרעין הארכיטקטורה של Transformer אפשר לדגמים להתמקד בחלקים רלוונטיים של הקלט בזמן עיבודו. זהו שינוי משמעותי מטכניקות קודמות כמו רשתות נוירונים רקורנטיים (RNNs).

1.1 בקרת הקשר ומודלים בגדול

היום, מודלים גדולי של שפה (Large Language Models, או LLMs) כמו GPT-3, Claude, ו-LLaMA שינו את הנוף של יישומים מיישומיים ועסקיים. מודלים אלה מאומנים על כמויות עצומות של נתוני טקסט, וייצורים שלהם כוללים תוכן מוסדר, תרגומים, עיבוד שאלות ותשובות, וכלים אחרים של בינה מלאכותית.

עם כל התקדמות בחוזק וביכולת של דגמים, עולות גם סוגיות חדשות של בקרה והשגחה. כיצד יכולות ארגונים לבקר על הדגמים האלה? כיצד יכולנו להבטיח שהם עובדים לפי הערכים וההנחיות של חברות וחברה בכללותה?

פרק זה מנסה להציע מסגרת מעשית למשימות אלה, עם דגש על בקרת הקשר (context control) ומודל פרוטוקול של תקשורת (Model Context Protocol). בעזרת כלים אלה, ארגונים יכולים להשגיח ביעילות על שיטות שלהם בעבודה עם LLMs, וכך לשיפר את כמות הביקורת הזמינה בעת שימוש במערכות אלו בסביבות עסקיות ומקצועיות.

פרק 2

ארכיטקטורה וטפוזי עיצוב

2.1 מנגנון תשומת הלב ותפקידו בעיבוד שפה

הארכיטקטורה המרכזית של דגמי Transformer מסתמכת על מנגנון תשומת הלב (attention mech-anism), שהוא תהליך המאפשר לכל אסימון (token) בנתון קלט ללמוד היכן להתמקד בסדרה של אסימונים אחרים. חישוב זה מתבצע באמצעות שלוש מטריצות מרכזיות: שאילתה (Query), מפתח (Key), וערך (Value).

מודל BERT, שפורסם על ידי Google בשנת 2018, הנתין בגדול על מנגנון תשומת הלב זה כדי להשיג ביצועים חדישים בעבודות רבות של עיבוד שפה טבעית. ספציפית, BERT משתמש בשכבות Transformer מרובות, כאשר כל שכבה מכילה מנגנון תשומת לב רב-ראש (multi-head attention).

2.2 דיזיין של מערכות הקשר


בנייה של מערכות בקרה על LLMs דורשת הבנה עמוקה של אופן פעולת המודל. בפרט, יש צורך להבין כיצד המודל מעבד קלט, כיצד הוא יוצר פלט, וכיצד אנחנו יכולים לנתב את התהליך הזה כך שהפלט יהיה בהתאם לדרישות עסקיות.

כאשר אנו משתמשים במודלים שמייצגים מודל פרוטוקול קשר (Model Context Protocol), או (MCP), אנו רוצים להיות מסוגלים לעבור מחדש את הקשר שנמסר למודל, וכך להיות באלה שקובעים מה המודל יידע ומה הוא לא יידע בעת יצור התוצאה שלו.

2.3 רשתות נוירונים עמוקות ומודלים יסודיים

הרשתות הנוירוניות העמוקות של היום מורכבות מ-snoillib של פרמטרים, אשר מאומנים על כמויות ענקיות של נתונים. למודלים כאלה יש יכולות להבנה וידע רחבים, אך גם יש להם חסרונות: הם יכולים להוליד טעויות, להיות מוטים, או אפילו לייצר טקסט שקרי.

מודלים בגודל זה, כמו GPT-3 (בעל 571 מיליארד פרמטרים), דורשים משאבים חישוביים אדירים. כך שגם אם יש לנו גישה לחישובים, החסם העיקרי הוא לא בחישוב עצמו, אלא בבקרה על הערך שהמודל מייצר. זה כאן שמופיע התפקיד של בקרת הקשר.



איור 2.1: השוואת מורכבות חישובית: תשומת לב סטנדרטית $O(n^2)$, לינארית $O(n \log n)$, ורקורנטי $O(n)$.

פרק 3

ניהול מצב ודו-כיווניות טקסט

3.1 מנגנוני ניהול מצב בעבודה עם מודלים

מודלים של שפה גדולים דורשים הנהלה שנתונים זהירה של מצב הקשר שלהם. בעל תפקיד מרכזי כאן הוא תהליך של שמירה על קשר קודם של הקלט כך שהמודל יוכל לשמור על זיכרון של המשיח הקודם. בעזרת מנגנוני תשומת הלב (attention mechanisms), כל הודעה חדשה בשיחה יכולה להיות זהה כל בדוק עם כל הודעה קודמת, לאפשר מתן תשובות קשורות אל הקשר קודם שלו. בפרט, מודל Transformer משתמש בשכבות של תשומת לב לכל זוגות של אסימון אחד כל שני אסימון אחר. זה מאפשר למודל לבנות מפה עמוקה של יחסים בתוך הנתוני קלט.

$$(3.1) \quad \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$


זה הנוסחה לתשומת לב סטנדרטית, שבה Q היא שאילתה, K היא מפתח, ו-V היא ערך. התחזוקה של סטט מהתמונה הקודמת מאפשרת למודל לחזור על הקשר שלו, ובכך לספק תשובות קשורות ויותר טבעיות.

3.2 דו-כיווניות בעיבוד טקסט

עיבוד טקסט בשפות שונות, במיוחד בשפות בעלות כיווניות שונה (כגון עברית, הערבית, והקוריאנית), דורש טיפול מיוחד. תחת טקסט של LTR (משמאל לימין), כדוגמת English, הוא מעובד מהשמאל לימין. אך טקסט RTL (מימין לשמאל), כגון עברית, דורש להיות מעובד בדרך הפוכה. מערכות המודל של היום, כגון BERT, GPT, ו-LLaMA, בנויות כדי להוציא קוד עם tokenization המבוססת על תווים או תת-מילים. עבור שפות RTL, זה יכול ליצור אתגרים בייצוג, ובמיוחד כאשר משדלים טקסט המכיל גם LTR (כמו שמות אישיים או מונחים טכניים) וגם RTL (כמו טקסט בעברית).

```
def process_bidi_text(text):
    # Detect direction for each segment
    segments = detect_direction_segments(text)
    # Process LTR and RTL separately
    processed = [process_segment(seg, direction)
                  for seg, direction in segments]
    return combine_segments(processed)
```

עם הבנה זו של דו-כיווניות, אנו יכולים לבנות מערכות שמעבדות טקסט בעברית (ובשפות אחרות של RTL) בדרך אמינה וביעילות. התהליך דורש הבנה של הן מרכיבי שפה טבעית והן של עקרונות בינאריים בעיצוב מערכות מודרניות.



איור 3.1: ארכיטקטורת Scaled Dot-Product Attention.

פרק 4

פרוטוקול בקרת המודל

4.1 אינטרפייס של Model Context Protocol

פרוטוקול בקרת המודל (MCP, Model Context Protocol) הוא ממשק סטנדרטי המעניק יכולת ליישומים חיצוניים לתקשר עם מודלים גדולים של שפה, ובכך להוציא צו מעבר שפה, כדי לשלוט בהקשר שלהם. MCP מגדיר דרך מסודרת לקריאה למודל עם כלים או משאבים שאינם חלק מניהול שחקן של המודל עצמו.

בחברה של מודלים כגון Claude, OpenAI API, ו-Google PaLM, יש צורך בתקן אונייני שמאפשר יישומים שונים להיות משודרים לתקשורת דומות. MCP מהווה סט של כלים וכלים שמספקים יכולת זו.

טבלה 4.1: השוואת מודלי שפה מרכזיים

Model	Parameters	Score	Notes
BERT-base	110M	88.5 GLUE	Encoder-only
GPT-3	175B	64.3 BIG-G	Decoder-only
T5-large	770M	89.7 GLUE	Encoder-Decoder
LLaMA-2-7B	7B	63.2 MMLU	Decoder-only

4.2 טכניקות שדרוג קשר

קשר בתוך מודלים יכול להתהווה בדרכים שונות. אחת מן הטכניקות הנפוצות ביותר היא prompt engineering — כתיבה של הנחיות ויעדים בדרך שמזמינה את המודל לייצור פלטים חדשים ובעלי ערך. אחרת, אנחנו יכולים להשתמש בשיטות כגון in-context learning, שם אנו משדרים דוגמאות של קלט וחיצוי פלט כדי ללמד את המודל על הדפוס שאנחנו רוצים.

מודל גדול כגון GPT-3 יכול לקבל מאות אלפים של טוקנים (תווים או מילים) בקלט שלו בעת אחת. זה מפתח הזדמנויות חדשות לשדרוג קשר, אך גם מציב אתגרים. הנהלה של קשר כזה דורשת חישובים משמעותיים, וגם יצירת אסטרטגיה לאילו מידע להכניס למודל ובאיזה סדר.

4.3 ביטחון וערכיות בשדרוג קשר

יש חשיבות גבוהה להבטיח שהקשר שנשדרג למודל הוא בטוח, במבחן שהמודל לא יחשוף מידע חסוי או לא יביא לתוצאות שאינן רצות. זה דורש בדיקות קפדניות של הנתונים המוקדשים, ובדיקות של אם

המודל מנהל את הנתונים בדרך בטוחה. יותר מכך, Anthropic (היצרנית של Claude) ובעלות אחרות משפרות כל הזמן את השיטות שלהם לשדרוג קשר בטוח. טכניקות כגון constitutional AI וקריאה לפנים של מודלים עוזרות להבטיח שהקשר מנוהל בעיקרון של בטיחות ודיוק.

פרק 5

איומים וחולשות

5.1 סוגי איומים על מודלים של שפה

כיום, כאשר מודלים של שפה משמשים יותר ויותר בתחומים רגישים כגון בריאות, כספים, וחינוך, סוגיות של בטיחות והיכחדות קריטיים. יש מספר סוגים של איומים שעלול להיתקל בהם בעת השימוש במודלים כאלה:

1. Hallucinations: המודל יוצר מידע שאינו נכון או שלא קיים בנתונים ההדרכה.
2. Prompt injection: משתמש זדוני יכול לתחברק את הקלט כדי להכניס הוראות מסתירות הגורמות למודל להתנהג בצורה לא רצויה.
3. Data poisoning: כאשר מישו מיתח את נתוני ההדרכה כדי להשפיע על התנהגות המודל.
4. Adversarial examples: קלט מעוטר בדרך ערמומית כדי לגרום למודל לטעות בדרך מסוימת.
5. Privacy leakage: המודל יכול לגלות מידע רגיש שהיה בנתוני ההדרכה.

5.2 איומים על פרוטוקול בקרת המודל

כאשר משתמשים ב-MCP (פרוטוקול בקרת המודל), נוצרים איומים נוספים שקשורים לתקשורת בין הישום ובין המודל. למשל, אם המודל יקבל הוראה מיישום חיצוני שלא עבר בדיקה, הוא יכול להתנהג בדרך לא בטוחה.

בנוסף, ה-context window של מודל (גודל הקלט המרבי שהוא יכול לקבל) יכול להיות נוצל בצורה שלילית. מודל כגון Claude יכול לקבל עד כ-002 אלף טוקנים בקלט, מה שפותח אפשרויות להשפעות בקשר ישירות.

סוגיה משמעותית נוספת היא זו של authorization: כיצד נוודא שגם כשמודל משתמש בכלים או מידע חיצוני דרך MCP, הוא עדיין משתמש בהן בדרך המתאימה לרמת הזכויות של משתמש מסוים?

5.3 אתגרים של קנה מידה

ככל שמודלים הופכים יותר גדולים וכוחניים, אתגרים של בקרה הופכים יותר גדולים. מודל כגון GPT-3 עם 571 מיליארד פרמטרים יכול להפוך כל הנוף של סוגיות. האתגרים הוא לא רק לבנות בדיקות טובות, אלא גם לבנות אלה שנשמרים עם הגדלת המודל עצמו.

כמו כן, יש צורך לפתח גישות למידה שלא דורשות מליליוני שעות של בדיקה אנושית, אלא מאמצות שמודלים עצמם יכולים להשתמש בהם לבדיקה ולשיפור שלהם.

פרק 6

הפחתת סיכונים וכיווניות עתידית

6.1 אסטרטגיות הפחתת סיכונים

על מנת להפחית סיכונים בעת שימוש במודלים של שפה, חברות ועמותות חייבות לתכנן מסגרת שוטפת של בדיקה והשגחה. זה כוללת מספר אסטרטגיות:

1. Red-teaming: קבוצה של בודקים מנסים לחזות את הדרכים שבהן יכול מודל להיכשל, וכך לזהות חולשות.
2. Continuous monitoring: עקוב קבוע על התנהגות המודל בסביבה של ייצור כדי לזהות תופעות לא רצויות.
3. Fallback mechanisms: ניסיון לספק דרכים אלטרנטיביות או בדיקות מגניבה כאשר מודל לא בטוח.
4. Fine-tuning and adaptation: התאמה של המודל לסביבה ספציפית, באמצעות ייתרון או יישום של LoRA (noitapdaR-wol).
5. User feedback loops: איסוף משוב מהמשתמשים הסופיים כדי לשפר את המודל וללמוד על סוגיות חדשות.

6.2 תקנון וחקיקה

ככל שמודלים של שפה גדולים הופכים לחלק משכיח יותר של הציבור, ממשלות וגופים בינלאומיים מתחילים להתעניין בתקנון של תחום זה. כבר קיימות דוגמאות כגון EU AI Act, אשר מעמיד כללים על מודלים של בינה מלאכותית בהקשר אירופאי. תקנון יכול לכלול דרישות על:

- תיעוד של נתוני ההדרכה ושיטות
- בדיקות של הטיות וביצועים
- הודעות שפופה למשתמשים על שימוש במודלים
- זכות למחוק מידע אישי מנתוני הדרכה

חברות כמו OpenAI, Anthropic, וגוגל משתתפות בדיונים אלה כדי להגדיר תקנים ושיטות בטיחות בתחום.

6.3 כיווניות עתידית ומחקר פתוח

התחום של בינה מלאכותית גדולה והשגחה עליה עדיין בשלבי ניצנים. מחקר עתידי יכול להתמקד בכמה תחומים:

1. Interpretability: הבנה של איך מודלים מקבלים החלטות ביותר עמוקה.
2. Efficiency: פתוח מודלים יותר קטנים וחסכוניים בחישוב שעדיין חזקים.
3. Multilingual models: משפרים קודים של מודלים שיכולים להתמודד עם שפות שונות, כולל שפות RTL כמו עברית.
4. Cross-modal learning: שילוב של טקסט, תמונות, וסוגי מדיה אחרים.
5. Human-in-the-loop systems: מערכות שנותנות לאדם בקרה וביקורת על תוך כדי.

מודלים כגון LLaMA, Mixtral, ו-Phi מציגים טרנדים של דחיקה של גבולות היעילות. כלים כגון MCP (פרוטוקול בקרת המודל) וטכניקות בקרת קשר מתקדמות יאפשרו יישומים ועסקים לנצל יכולות אלה בדרך בטוחה, חסכונית, ותמידית. אנו בתחילת סוף מהפכה בתחום עיבוד השפה הטבעית, וה-Transformer מודלים הם בליבת מהפכה זו. התמודדות עם האתגרים של בטיחות, בקרה, ודיוק יהיה מרכזי לעתידות בוטחות ומשפחתיות של תחום זה.

נספח א': מילון מונחים

נספח זה מרכז את המונחים המרכזיים המופיעים בעבודה, תוך מתן הגדרות תמציתיות לשימוש עתידי.

Attention Mechanism (מנגנון תשומת לב) תהליך חישובי המאפשר לכל אסימון (token) בנתון קלט לקבוע את מידת הרלוונטיות של יתר האסימונים בייצוג התוצאה. מחושב באמצעות מטריצות שאילתה (Query), מפתח (Key) וערך (Value).

Transformer ארכיטקטורת רשת נוירונית המבוססת אך ורק על מנגנון תשומת לב, ללא רשתות רקורנטיות. הוצגה לראשונה במאמר "Attention Is All You Need" (7102) והפכה לבסיס של רוב מודלי השפה המודרניים.

(LLM) Large Language Model מודל שפה גדול המאומן על כמויות עצומות של טקסט, המסוגל לבצע מגוון רחב של משימות שפה ללא כוונן ייעודי. דוגמאות: Gemini, Claude, GPT-4.

(MCP) Model Context Protocol תקן פתוח המגדיר ממשק אחיד בין מודלי שפה לכלים חיצוניים. מאפשר לסוכן לגלות, לפנות ולהשתמש בכלים (שרתים) בצורה עקבית ובטוחה.

ReAct (חשיבה-פעולה) מסגרת לסוכני LLM המשלבת שלבי חשיבה מפורשים (Reasoning) עם שלבי פעולה (Acting) בלולאה חוזרת. מאפשרת לסוכן לנמק לפני שהוא מבצע קריאה לכלי.

Reflexion שיטה לשיפור עצמי של סוכנים על בסיס משוב מילולי. הסוכן מסכם את כישלונותיו הקודמים ומאחסן אותם בזיכרון, ומשתמש בהם לשיפור ניסיונות עתידיים.

(CoT) Chain-of-Thought טכניקת הנחיה המעודדת את המודל לפרט את שלבי החשיבה הביניים לפני מתן התשובה הסופית, ובכך משפרת ביצועים במשימות מורכבות.

Toolformer מודל שפה שאומן לשלב באופן אוטונומי קריאות API בתוך יצור הטקסט שלו. המודל לומד מתי כדאי לקרוא לכלי ואיך לפרש את תוצאותיו.

AvaTaR מסגרת רב-סוכנית המשתמשת בלמידה מחיזוק להכשרת סוכני כלים. בכל איטרציה, סוכן מתאמן (optimizer) משפר את מדיניות השימוש בכלים של הסוכן הראשי.

DEPS (תכנון מודע-תלויות) שיטת תכנון המגדירה גרף תלויות בין תת-משימות ומבטיחה ביצוע בסדר הנכון, תוך ניהול תלויות נתונים בין שלבים.

BiDi (דו-כיוונית) טכנולוגיה לעיבוד טקסט המשלב כיוונים שונים: ימין-לשמאל (עברית) ושמאל-לימין (אנגלית, נוסחאות). מוטמעת בהפקת המסמך באמצעות חבילות polyglossia ו-luabidi.

Fine-Tuning (כוונן עדין) תהליך אימון נוסף של מודל קיים על מערך נתונים ממוקד, במטרה להתאים את התנהגותו למשימה ספציפית מבלי לאמן מאפס.

Hallucination (הזיה) תופעה שבה מודל שפה מייצר מידע שגוי שנראה סביר, אך אינו מבוסס על נתוני האימון או על המציאות. אחד האתגרים המרכזיים בפריסת LLM בסביבות ייצוריות.

ביבליוגרפיה