

ארכיטקטורת הטרנספורמר ועיבוד שפה טבעית בעברית

Avi Ayeli — 300228160

5 ביוני 2026

תוכן העניינים

2	1 מבוא לארכיטקטורות Transformer
2	1.1 הקדמה: מהפכה בעיבוד שפה טבעית
2	1.2 בעיית האילוך הרקורנטי וקיום הטעם
2	1.3 עדכוני מפתח בארכיטקטורות דגם שפה
3	1.4 יעדים ותרומות של הספר הזה
5	2 ארכיטקטורת השנאי
5	2.1 יסודות המנגנון-קשב
6	2.2 ארכיטקטורת Multi-Head Attention
6	2.3 השכבות הלינאריות וההנדסה הפנימית
6	2.4 נורמליזציה וחיבורים שזורים
6	2.5 קידוד מיקום וטבלאות הטמעה
7	2.6 סיכום ושימוש ב-ELECTRA
8	3 דו-כיוונית
8	3.1 ארכיטקטורת Sequence-to-Sequence LSTM
8	3.2 תחזוקת רגרסיה של פרמטרים: משרעת, תדר ופאזה
9	3.3 מנגנוני קשב וחיבורים שזורים
10	4 ארכיטקטורות מתקדמות
10	4.1 עיבוד בתחום התדר: STFT וסינון ספקטרלי
11	4.2 ארכיטקטורות היברידיות CNN-LSTM
11	4.2.1 ניסוח הארכיטקטורה
11	4.2.2 הצדקה וביצועים
11	4.2.3 שיקולים מעשיים
12	5 עברית וטיפול בשפות מורפולוגיות עשירות
12	5.1 אתגרים של עברית: מורפולוגיה, ניתוח ודו-משמעות
12	5.2 BERT: AlephBERT מכוונת לעברית
13	5.3 ביצועים והשוואה לארכיטקטורות אחרות
14	6 הערכה ויישור בסיסי
14	6.1 מדדי הערכה לפרדת אותות
15	6.2 השוואה בין עיבוד קלאסי לבין למידה עמוקה

פרק 1

מבוא לארכיטקטורות Transformer

1.1 הקדמה: מהפכה בעיבוד שפה טבעית

לאורך עשרים השנים האחרונות, עיבוד שפה טבעית (NLP) התפתח מכלים סטטיסטיים בסיסיים אל תוך מערכות למידה עמוקה המסוגלות לתפוס קשרים סימנטיים מורכבים בטקסט. עם זאת, עד שנת 2017, רוב מודלי הרשתות העמוקות בתחום זה התבססו על Recurrent Neural Networks (RNNs) וגרסאות משופרות שלהן כמו Long Short-Term Memory (LSTM) [14]. למרות יעילותם היחסית, הרשתות הרקורנטיות סבלו מבעיה משמעותית: קשיות בתפיסה של קשרים לטווח ארוך ביותר בטקסט, בגלל בעיית ההתמוטטות והתפוצצות של הגרדיאנטים במהלך ההכשרה. בשנת 2017, פרסמו ווסואני וחוקרים נוספים מ-Google עבודה המשפיעה שכותרתה "Attention Is All You Need" — עבודה שהציגה את ארכיטקטורת Transformer. דגם חדש זה סילק את הצורך ברקורנציה לחלוטין, וממנו הביא את מנגנון ה-self-attention לחזית העיצוב. התוצאה הייתה מהפכה: מודלים מתקדמים יותר שיכלו להיות מהופצים ביעילות רבה יותר על פני יחידות עיבוד מרובות (GPU/TPU), ובעת ובעונה אחת, הם השיגו ביצועים חדישים בשורה של משימות NLP.

1.2 בעיית האילוך הרקורנטי וקיום הטעם

רשתות RNN קלאסיות מעבדות רצפים באופן סדרתי — כל אלמנט בקלט מעובד רק לאחר עיבוד האלמנט הקודם. עיצוב סדרתי זה יוצר שתי בעיות עיקריות:

1. **חוסר הקביל:** בגלל תלות הרקורנציה, לא ניתן לעבד אלמנטים שונים בו-זמנית, מה שהופך הדרכה וחיזוי למבוצעים ממאנים למודלים ארוכים.

2. **עיוותי קשר לטווח ארוך:** Gradient flow דרך צעדי זמן רבים גורם לבעיות כמו התמוטטות וריבוי של גרדיאנטים, המקשות על לימוד קשרים בין אלמנטים רחוקים בטקסט.


ארכיטקטורת Transformer פותרת בעיות אלו בתשומת לב עצמית (self-attention), המאפשרת לכל אלמנט לקבל קשר ישירות אל כל אלמנט אחר ברצף, ללא רקורנציה. זה פותח את הדלת לעיבוד מקביל מלא וקשרים לטווח ארוך יותר בעקביות.

1.3 עדכוני מפתח בארכיטקטורות דגם שפה

מאז הצגת Transformer, המחקר בתחום NLP התרכז על כיוונים וטוב של עקרונות הבסיס. שלושה מודלים משפיעים יותר זה שלפנינו:

$$(1.1) \quad \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

BERT [3] הטמיע Transformers דו-כיווניים עם הדרכה קדם-מטלה על קורפוסים ענקיים, והשיג ביצועים טובים ביותר בעשרות משימות downstream. בעקבות זה, דגמים גדולים יותר כמו GPT-2 [1] הדגישו שעם הרחבה של נתוני הדרכה וגודל דגם, ניתן להשיג אבדות פחותות ביותר בחיזוי הטוקן הבא. GPT-3 [9] הוריד הדגמה זו לקיצוניותה, והראה שמודלים בגודל מרה-גדול יכולים לענות על משימות חדישות עם רק כמה דוגמאות או בלעדיהן (zero-shot learning ו-few-shot).



איור 1.1: Transformer Encoder Block Diagram (Python-generated)

1.4 יעדים ותרומות של הספר הזה

כתאב זה מוקדש לחקר מעמיק של ארכיטקטורות Transformer והיישומים שלהן בעיבוד שפה טבעית. אנחנו נחקור:

- את המיכניקה המפורטת של מנגנון ה-self-attention

- את תפקיד ה-positional encoding- בהעברת מידע מיקום
- את ההבדלים בין encoder לבין decoder ארכיטקטורות
- דוגמאות מעשיות לדרך יישום מודלים אלו

בנוסף, נשקול השפעות הנדסיות כמו יעילות זיכרון, שיפור הדרכה, ופתרונות עבור רצפים ארוכים מאוד. הקוראים יצאו מכתאב זה בעלי הבנה עמוקה לא רק איך Transformers עובדים, אלא למה הם משדרגים שיטות קודמות וכיצד הם מהווים הבסיס לדור חדש של מערכות בינה מלאכותית.

פרק 2


ארכיטקטורת השנאי

2.1 יסודות המנגנון-קשב

מנגנון הקשב (Attention Mechanism) מהווה את הלב הפועם של ארכיטקטורת השנאי (Trans-former). בניגוד לרשתות נוירונים רקורנטיות המעבדות נתונים ברצף ודורשות זמן חישוב ריבועי בקנה מידה של אורך הרצף, השנאי מאפשר עיבוד מקביל של כל התאימים בו-זמנית. כפי שתואר ב-[14], מנגנון הקשב מחשב מטריצת משקלים המשדכת כל אלמנט בקלט עם כל אלמנט אחר בו בשלב יחיד. הנוסחה החישובית למנגנון הקשב היא:

$$(2.1) \quad \text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

כאשר Q (Query), K (Key), ו- V (Value) הן מטריצות המתקבלות מהשכבות הקודמות. הגורם $\sqrt{d_k}$ משמש לנרמול כדי לשמור על יציבות מספרית וקצב ההתכנסות בהדרכה. לאחר חישוב פונקציית ה-softmax, המשקלים מוחלים על מטריצת הערכים כדי לייצר פלט קשוב. מורכבות הזמן של פעולת ה-self-attention היא $O(n^2 \cdot d)$ כאשר n הוא אורך הרצף ו- d הוא ממד ההטמעה — יתרון ברור על פני ה-RNN בו הזמן הסדרתי גדל לינארית אך ללא מקביליות.



איור 2.1: Attention Complexity

2.2 ארכיטקטורת Multi-Head Attention

בעוד שמנגנון קשב יחיד יכול לתפוס קשרים מסוימים בין נתונים, השנאי משתמש בעשרות ראשי קשב (Attention Heads) במקביל. כל ראש מאומן באופן עצמאי וחוקר היבטים שונים של הנתונים. השימוש בראשים מרובים מגביר את יכולת המודל ללמוד תבניות מורכבות וליצור ייצוג עשיר של הקלט. כמתואר ב-[3], ארכיטקטורת Multi-Head Attention מאפשרת למודל להתמקד בחלקים שונים של הרצף בו-זמנית. לדוגמה, חלק מהראשים עשויים ללמוד קשרים תחביריים (Syntactic Relations) בעוד שאחרים לומדים קשרים סמנטיים (Semantic Relations). המשוואה המתארת Multi-Head Attention היא:

$$(2.2) \quad \text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$$

כאשר כל head מחושב לפי:

$$(2.3) \quad \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

2.3 השכבות הלינאריות וההנדסה הפנימית

לאחר שכבת Multi-Head Attention, הנתונים עוברים דרך רשת נוירונים עמוקה בעלת שכבות לינאריות עם פונקציית הפעלה לא-לינארית (בדרך כלל ReLU או GELU). שכבה זו, המכונה Feed-Forward Network (FFN), מייצגת הנדסה פנימית משמעותית. כל יחידה בשכבה הלינארית הראשונה לומדת שילובים של תכונות הקלט, מה שמאפשר למודל לתפוס קשרים לא-לינאריים מורכבים. הנוסחה של FFN היא:

$$(2.4) \quad \text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

מימד הביניים (Hidden Dimension) של שכבה זו בדרך כלל גדול פי 4 מממד הפלט, כפי שנחקר ב-[1]. בחקר יסודי זה, הוכח כי הגדלת מימד הביניים משפרת את ביצועי המודל, אם כי בעלות חישובית מוגברת.

2.4 נורמליזציה וחיבורים שיריים

חיבורים שיריים (Residual Connections) ונורמליזציה בשכבה (Layer Normalization) משמשים מטבעות חיוני בארכיטקטורת השנאי. כל תת-שכבה (sub-layer) מכילה חיבור שירי המוסיף את הקלט המקורי לפלט המעובד:

$$(2.5) \quad \text{LayerNorm}(x + \text{SubLayer}(x))$$

חיבורים אלה מקלים על ההדרכה של מודלים עמוקים מאוד על ידי הבטחת שדרגות גדול גם בשכבות העמוקות. נרמליזציה בשכבה משמשת לשיפור יציבות האימון וצמצום התלות בקצב הלמידה, כפי שהוכח ב-[9].

2.5 קידוד מיקום וטבלאות הטמעה

בניגוד לרשתות נוירונים רקורנטיות המעבדות רצף אחרי רצף, השנאי מעבד את כל הרצף בו-זמנית. לכן, המודל דורש אמצעי לקידוד המידע החיובי של כל אלמנט בתוך הרצף. זה מושג באמצעות Positional Encoding, המוסיף וקטור תלוי-מיקום לכל הטמעה של אלמנט.

הנוסחה של קידוד המיקום היא:

$$(2.6) \quad PE(pos, 2i) = \sin(pos/10000^{2i/d_{model}})$$

$$(2.7) \quad PE(pos, 2i + 1) = \cos(pos/10000^{2i/d_{model}})$$

כאשר pos הוא המיקום בתוך הרצף ו- i הוא האינדקס של הממד בוקטור ההטמעה. בגרסאות מודרניות של שנאים, כמו LLaMA ([11]), השימוש בקידוד מיקום רוטציוני (Rotary Position Embeddings) משפר את הטוענות של המודל לרצפים ארוכים.

2.6 סיכום ושימוש ב-ELECTRA

ארכיטקטורת השנאי הפכה לתשתית למודלים עדכניים של טיפול בשפה טבעית. כמודל ה-ELECTRA שמתואר ב-[2], הם מצטיינים בימים המשימות של סיווג טקסט וחילוץ מידע. השילוב של מנגנון-קשב, פיד-פורוורד רשתות, קידוד מיקום, ונרמליזציה בשכבה יוצר מודל חזק וניתן להרחבה הגם לבעיות מעבדה קשות ומורכבות.

עם זאת, ארכיטקטורת השנאי אינה הפתרון היחיד לעיבוד רצפים. בפרק הבא נסקור את רשתות LSTM הרקורנטיות — הקדמה ההיסטורית לשנאי — ואת השימוש בהן לחילוץ פרמטרים מאותות סינוסואידליים. בdomain של עיבוד אותות (כגון הפרדת קול ממיזוג), היתרון המיוחד של RNN הוא עיבוד מקוון בו כל דגימה מוזנת ברצף — גישה המאפשרת עיבוד בזמן-אמת בזיכרון מוגבל, שבו מורכבות $O(n^2)$ של השנאי הופכת לגורם מגביל.

פרק 3

דו-כיווניות

3.1 ארכיטקטורת Sequence-to-Sequence LSTM

ארכיטקטורת Sequence-to-Sequence המבוססת על רשתות LSTM מהווה אבן דרך בתחום הלמידה העמוקה לעיבוד סדרות זמן [13]. המודל מורכב משני רכיבים עיקריים: מקודד (encoder) שמעבד את הרצף הקלט ויוצר ייצוג וקטורי מופשט, ופוענח (decoder) שמשתמש בייצוג זה כדי ליצור את הרצף הפלט. בהקשר של חילוץ פרמטרים מאותות סינוסואידליים, גישה זו מאפשרת לרשת ללמוד את הדינמיקה הסיבוכה של האותות רועשים ולייצר אותם בצורה דחוסה וניתנת לעיבוד.

המקודד מעבד את ערכי הקלט ברצף ויוצר סדרה של מצבים חבויים המכילים מידע מצטבר על האות כולו. בשלב הראשון, המודל מבצע הטמעת קלט, כלומר המרת כל ערך למימד גבוה-ממדי המתאים ללמידה יעילה. לאחר מכן, המקודד LSTM משדרג את המצב החבוי בהתאם לקלט הנוכחי, תוך שמירה על מידע זיכרון מטווה ארוך. בתום עיבוד כל הרצף, המקודד מוציא "וקטור הקשר" (context vector) המהווה סיכום דחוס של המידע במקור.

הפוענח משתמש בוקטור הקשר הזה כמצב ראשוני ויוצר את הרצף הפלט צעד אחד בכל פעם. בכל שלב זמן, הפוענח מעבד את הפלט הקודם (או סימול התחלה בשלב הראשון) ויוצר את ערך הפלט הבא. מבנה זה מאפשר לרשת ללמוד קשרים מורכבים בין הקלט לפלט, בעיקר כאשר משולבים בה מנגנוני קשב מתקדמים [8]. בטבלה הבאה מוצגים ההבדלים העיקריים בין RNN/LSTM לבין ארכיטקטורת Transformer:

טבלה 3.1: השוואה בין RNN/LSTM לבין Transformer

Property	RNN / LSTM	Transformer
Processing order	Sequential (step-by-step)	Fully parallel
Time complexity	$O(n)$ serial steps	$O(n^2 \cdot d)$ parallel
Long-range deps	Difficult (vanishing grad)	Direct (self-attention)
Memory footprint	$O(1)$ hidden state	$O(n^2)$ attention matrix
Training signal	BPTT (unstable)	Stable, parallelizable
Real-time inference	Natural (streaming)	Requires full sequence

3.2 תחזוקת רגרסיה של פרמטרים: משרעת, תדר ופאזה

הגישה של רגרסיה ישירה לתחזוקת פרמטרים של גלים סינוסואידליים מנצלת את יכולת הרשתות העמוקות ללמוד מיפויים מורכבים ממרחב הקלט למרחב הפרמטרים [4]. במקום לצפות מהמודל לשחזר את האות כולו, אנו מאמנים אותו לחזות בדיוק שלושה ערכים: המשרעת (A , amplitude), התדר

(frequency) f , והפאזה (phase) ϕ של הגל הבסיסי. גישה זו מפחיתה משמעותית את מורכבות הפלט ומשפרת את הדיוק של תחזוקת הפרמטרים בתנאים רועשים. הגדרת בעיית הרגרסיה הולכת כדלקמן: בהינתן אות $x(t) = A \sin(2\pi f \cdot t + \phi) + n(t)$ כאשר $n(t)$ היא רעש גאוס, הרשת צריכה לפלוט משלוש הערכים $\hat{A}, \hat{f}, \hat{\phi}$ כך שהשגיאה הריבועית הממוצעת (MSE) בין הפרמטרים האמיתיים לחזויים מוזערת. מסקנה חשובה היא שחילוץ פרמטרים מניב מידע מובנה יותר מאשר שחזור הנקודות הגולמיות, כאשר החלק הקידודי של הרשת יכול להתמקד בתכונות ספקטרליות רלוונטיות לקביעת כל פרמטר. השימוש בטכניקות דוגמית מונחה בעומק (supervised learning) עם data augmentation משיג שיפורים משמעותיים בהכללה למודלים שלא נתקלו בהם בעת האימון [5]. כאשר משתמשים בנתונים סינתטיים המייצרים משרעות, תדרים ופאזות שונות בטווחים רחבים, הרשת לומדת ייצוגים חזקים המסוגלים להתמודד עם שונות רחבה. בנוסף, הפעלת טכניקות כמו batch normalization וירידה מוקדמת (early stopping) משפרת את היציבות של האימון ומונעת התאמת יתר.

3.3 מנגנוני קשב וחיבורים שירים

שילוב מנגנוני קשב (attention mechanisms) בתוך ארכיטקטורת Sequence-to-Sequence משנה באופן יסודי את יכולת הרשת להתמקד בחלקים רלוונטיים של רצף הקלט [13]. במקום שהפוענח יסתמך על וקטור קשר יחיד המכיל מידע מדחוס על כל הרצף, מנגנון הקשב מאפשר לו לגשת למצבים החבויים של המקודד בצורה דיפרנציאלית, עם משקלים שמתבררים במהלך האימון. לכל שלב זמן בפוענח, המודל מחשב ציוני קשב המתארים עד כמה "קשור" כל מצב נסתר של המקודד לעבודה הנוכחית. הגדרת מנגנון הקשב מתבטאת באמצעות המשוואה הבאה, בה h_i הוא המצב החבוי של המקודד בשלב i , ו- s_t הוא המצב החבוי של הפוענח בשלב t :

$$(3.1) \quad \text{attention}(s_t, \{h_i\}) = \sum_{i=1}^T \alpha_{t,i} h_i, \quad \alpha_{t,i} = \frac{\exp(e_{t,i})}{\sum_{j=1}^T \exp(e_{t,j})}$$

כאשר $e_{t,i}$ הוא ניקוד קשב המחושב באמצעות פונקציית ניקוד (scoring function) כמו מכפלה דוטית או רשת עצבית קטנה.

חיבורים שירים (residual connections) משמשים להקלה על בעיות כמו היעלמות גרדיאנטים בעומקים רבים של רשת [7]. בחיבור שירי, הפלט של שכבה מחוברת ישירות לקלט שלה, כלומר $y = f(x) + x$ במקום רק $y = f(x)$. בהקשר של מודלים עם קשב, חיבורים שירים מאפשרים לגרדיאנטים לזרום בקלות דרך הרשת, וגם לשמור על מידע "בדרך כול" המחלף בשכבות הרבות. השילוב של קשב וחיבורים שירים יוצר ארכיטקטורה היברידית מחזקת (hybrid architecture) המשיגה ביצועים עדיף על קו בסיס קלאסי בחילוץ פרמטרים של גלים סינוסואידליים [12].

פרק 4

ארכיטקטורות מתקדמות

4.1 עיבוד בתחום התדר: STFT וסינון ספקטרלי

בפרקים הקודמים, התמקדנו בעיבוד אותות בתחום הזמן בשיטה ישירה, כאשר רשתות LSTM מנסות ללמוד מיפוי מאותות רועשים לאותות נקיים. אולם, גישה זו מטילה על הרשת את הנטל של ממידול מורכב של קשרים זמניים ארוכים בעת בחינת כל דגימה בזמן. חלופה עוצמתית היא עיבוד בתחום התדר, המשתמש בתמרת פורייה לזמן קצר (Short-Time Fourier Transform, STFT) ככלי קדם-עיבוד.

תמרת STFT מחלקת את האות לחלונות זמן חופפים ומחשבת את הייצוג התדר עבור כל חלון. התוצאה היא ספקטרוגרמה של מקדמים מרוכבים (או גודלים ופאזות) בדו-מימד של זמן ותדר. רישום מתמטי:

$$(4.1) \quad \text{STFT}(t, f) = \int_{-\infty}^{\infty} x(\tau) \cdot w(\tau - t) \cdot e^{-j2\pi f\tau} d\tau$$

כאשר $w(\tau)$ הוא חלון (לדוגמה, חלון Hann) המדכא עיצוב של קצוות וחפיפה. סינון ספקטרלי (spectral masking) הוא טכניקה שבה מודל למידה עמוקה יוצר מסכה בין 0 ל-1 עבור כל תא זמן-תדר בספקטרוגרמה. מסכה זו מכפלת את הספקטרוגרמה המקורית כדי לעכל רעש ולהשאיר את גל הסינוס הרצוי. המטרה בהדרכה היא:

$$(4.2) \quad \hat{Y}(t, f) = M(t, f) \cdot X(t, f)$$

כאשר $M(t, f)$ היא המסכה (פלט הרשת), $X(t, f)$ היא הספקטרוגרמה הרועשה, ו- $\hat{Y}(t, f)$ היא הספקטרוגרמה המפוקחת. מטרת אימון משופרת היא להשוות את הגודל הספקטרלי הצפוי (המחושב מגל הסינוס הנקי) לתוצאת הסינון. יתרונות הגישה הספקטרלית כוללים:

1. Sparsity: רעש לעתים קרובות פרוש על פני תדרים רבים, בעוד שגל הסינוס תופס כמה תדרים בלבד. זה הופך את בעיית הסינון לקלה יותר ללמידה עמוקה [15].

2. Interpretability: ניתן לראות ישירות אילו רגיונות תדר-זמן הרשת דיכתה, מה שעוזר בהבנת ההחלטה.

3. Generalization: מודל הסינון הספקטרלי מתוודע כללית יותר על פני טווחי תדר שונים מאשר רשת זמן-מימדית טהורה.

אחרי סינון וחזרה לתחום הזמן דרך תמרת STFT הפוכה (inverse STFT, iSTFT), אנו מממשים בעיית הפרדת אותות בדיוק גבוה וביעילות חישובית.

4.2 ארכיטקטורות היברידיות CNN-LSTM

ארכיטקטורות היברידיות המשלבות קונבולוציה עם רשתות רקורנטיות קדמו על פני שנים בעיבוד תמונה וקולות [8]. בהקשר של הפרדת אותות סינוס, שילוב זה חזק במיוחד מכיוון שהוא משלב עיבוד מקומי (CNN) עם בחינה גלובלית (LSTM).

4.2.1 ניסוח הארכיטקטורה

ארכיטקטורה טיפוסית של CNN-LSTM מחולקת לשלושה שלבים:

- CNN Feature Extraction:** כניסת האות (או ספקטרוגרמה) עוברת דרך שכבות קונבולוציה 1-D. כל אחת מכלולות תקבול מקומי בעלות גודל קריא וריפוד סימטרי, ובעלות ReLU כפונקציית הפעלה. במקום הפולינג, נשתמש לפעמים בסגירה אדפטיבית (adaptive pooling) כדי להפחית מימדיות לאורך הזמן. בחירת מספר סנני 46–652 בתוך כל שכבה נמצא בעיתוי פרקטי.
- BiLSTM Temporal Modeling:** תמונות המאפיינים (features) מוחזקות לתוך LSTM דו-כיווני עם 652–821 יחידות סמויות. זה מאפשר לרשת ללמוד תלות זמנית ארוכות טווח, ולהשתמש בהקשר מעבר ומאחור. ברור, סדר הזמן משמר בתחום זה.
- Decoder (CNN or Linear):** לאחר מכן, הפלט של ה-LSTM (סדרת וקטורים) מועבר דרך שכבת דקידוד כדי לשחזר את האותות בתחום הזמן או בתחום התדר. אפשרויות: (א) שכבות קונבולוציה חוזרות עם היפוך עמוד (transposed convolution), או (ב) שכבה צפופה עם צורת חזרה לממד המקורי.

4.2.2 הצדקה וביצועים

הגיגיו של שילוב זה הוא כי CNN לוכד תבניות מקומיות קצרות טווח (כמו רעש בצורת דופק או שינויים מהירים), בעוד LSTM מתמקד בתלות ארוכות טווח (כמו התנועה הדורגת של גל סינוס). בחקירות אמפיריות, ארכיטקטורות CNN-LSTM השיגו שיפור במידת הרעש (SNR) עדיפות בהשוואה לרשתות LSTM בלבד, במיוחד בטווח תחתון של SNR (20–dB), שם ההשפעה הגרועה של רעש היא לוחטת. הדיווח האופייני הוא שיפור של 2–4 dB בפלט SNR על פני בדיקה לא נראית [8].

4.2.3 שיקולים מעשיים

היתרונות:

- **Reduced model size:** CNN משמשים כטוחן מיוחד, מה שמפחית את מספר הפרמטרים בשלב LSTM.
- **Robustness to shifting:** קונבולוציה היא שוויון-בלתי משתנים, כך שדפוסים מקומיים מזוהים בכל הסדר הזמן.
- **Easier training:** שילוב זה מתכנס מהר יותר מ-LSTM טהור בהרבה מקרים בגלל ההנקה של CNN.

החסרונות:

- **Hyperparameter tuning:** בחירת גודל קריא, מספר שכבות, ומספר סנני דורשת כיוול זהיר.
- **Computational overhead:** בעוד CNN מצמצם מימדיות, קונבולוציה עצמה יש עלויות זמן-הרצה.

פרק 5

עברית וטיפול בשפות מורפולוגיות עשירות

5.1 אתגרים של עברית: מורפולוגיה, ניתוח ודו-משמעות

עברית משתייכת למשפחת השפות השמיות, המאופיינות במורפולוגיה עשירה וסבוכה. בניגוד לשפות אינדו-אירופיות כמו אנגלית, עברית משתמשת בשורשים תלת-אותיביים (כגון SH-M-R בשורש שמר) המשמשים קדם-קידודי לחיתוך משפחות מילים שלמות. כל שורש יכול להיות שונה דרך תבניות מורפולוגיות, קידומות וסיומות, מה שמוביל לתפוקה צפויה של צורות מילה שונות מאותו שורש יחיד. דוגמה קנונית: השורש SH-M-R (שמר) ניתן להצמיד ל-8 תבניות מתוך 61 התבניות הקאנוניות בעברית, כל אחת כותבת בעברית כמילה שונה: "שמר" (שמר), "שמורה" (שמרה), "שימור" (שמור), וכו'. קידומות וסיומות מגבירות עוד יותר את הדרגה של דו-משמעות: הסיומת "ים" (ים) יכולה להיות פורמה גבוהה ללא בחירה (פחוות) או קישור לשם שנקרא מישהו אחר ללא דרך אמצעית (משך אחר מישהו).

בעברית מודרנית, שיעור הדו-משמעות המורפולוגית גבוה במיוחד. לפי [6], סימנים בודדים בטקסט עברי יכולים להישמר עד שלוש דרכים או יותר ללא דרך כל שכן. לדוגמה, המילה "הספר" (הספר) יכולה להיות (1) "ה" (הם) + "ספר" (ספר) עם הרמה זו, או (2) "ה-" (ה-) + "סיפור" (סיפור) עם שם שנקרא ללא קישור, או (3) "ה-" + "סיפור" (סיפור) + "ה-" (ה-). הניתוח היחיד של אי-דו-משמעות מורפולוגית חוצה פעולות ניתוח קידומות/סיומות (tokenization) וניתוח דקדוקי (parsing), מה שמדרוג את המטלה הנתונה.

5.2 AlephBERT : BERT מכוונת לעברית

AlephBERT הוא מודל BERT בידי רקציונלי שתורגם במיוחד לעברית, כפי שמתואר ב-[10]. בניגוד לשימוש במודלי BERT רגילים (כמו mBERT) שאומנו על קורפוסים רב-לשוניים גדולים הכוללים סכום קטן יחסית של נתונים בעברית, AlephBERT הוא מודל חד-לשוני אשר הוא מאומן באופן בלעדי על קורפוס עברי מתודלק, מה שמאפשר קידוד לשוני עמוק יותר.

הוקטוריה של AlephBERT הותאמה לעברית: אוצר המילים (vocab) שלה הוא בעברית גרידא, מה שמאפשר פיצול תת-מילה (sub-word tokenization) יעיל יותר מאלה שמשתמשים במודלים רב-לשוניים. הקורפוס שעליו הוא התאומנו הוא קורפוס עברי מרוכז הכולל טקסטים מוועדים, וויקיפדיה בעברית, וטקסטים אקדמיים, כולם מתודלקים על פי תקן.

בדיקת ביצועים של AlephBERT על מטלות עברי (כמו תיוג מילים, ניתוח תלות, וניתוח סנטימנט) הראו שביצועים עדיפים ביחס למודלים רב-לשוניים כגון mBERT. כאשר מדבים על מטלות ספציפיות לעברית, AlephBERT מגיע ל-69% דיוק בניתוח מורפולוגי, כמו שמוצג ב-[10]. זה מדגיש את החשיבות של מודלים בנויים ספציפיים לשפה כאשר מטלות מורפולוגיות עשירות.

עם זאת, אתגרים נמשכים קיימים. AlephBERT עדיין מחוסר הבנה עמוקה של משמעויות דקדוקיות מורכבות, בעיקר כשמטלות כוללות הבחנה בין צורות מילים שנדמות זהות אך שמורות

בהקשרים שונים. קידום נוסף בתחום הניתוח המורפולוגי-דקדוקי דרושה טיפול בעיות דקות של עברית שאינן נהנות ממודלים גדולים שאומנו על מיליארדי מילים באנגלית.

5.3 ביצועים והשוואה לארכיטקטורות אחרות

כדי להבין את ערך AlephBERT בהשוואה לחלופות אחרות, יש לבחון ביצועים על מטלות עברי מוגדרות. ב-[10], מוצגת השוואה בין AlephBERT, mBERT (מודל רב-לשוני), XLM-R (מודל רב-לשוני מאומן על קורפוס גדול יותר), וחוקים ניתוח מקובלים בעברית.

בניתוח סנטימנט על קורפוס עברי, AlephBERT משיג דיוק של 78%, בהשוואה ל-28% עבור mBERT ו-48% עבור XLM-R. בניתוח תלות דקדוקית, AlephBERT מגיע ל-UAS (Unlabeled Attachment Score) של 5.49%, חזק משמעותית מ-2.19% של mBERT. בניתוח מורפולוגי עם תאימות תיוג טוקן, AlephBERT משיג 8.59%, ביחס ל-3.09% עבור mBERT.

הדקדוקים הקונונציונליים שנבנו על ידי שום מערכות מקובלות יותר הושקעו בעבור, לא השוו במישרין לממודלים נירונים. עם זאת, אנו יכולים להערים כי פער הביצועים בין מודלים נירונים מכוונים לעברית לבין מודלים רב-לשוניים הוא משמעותי, כשהפער גדול יותר ככל שמטלה מורפולוגית זו עשירה יותר.

מקום אחד בו אתגרים נמשכים קיימים הוא בהסקה בזמן-אמת. מודל AlephBERT הוא משקל בינוני (011 מיליון פרמטרים), מה שהופך אותו למאומן רק על GPUs גדולים או טוב יותר. שינויים מודעים של מודל זה עבור יישומים ניידים או ערוצים קולים (כמו עברית דיבור), עדיין ממתנים לחקר עתידי ופיתוח.

פרק 6

הערכה ויישור בסיסי

6.1 מדדי הערכה לפרדת אותות

הערכה כמותית של איכות פרדת האותות היא שלב קריטי בתהליך פיתוח ובדיקה של מערכות למידה עמוקה לעיבוד אותות. מדדי הערכה מאפשרים השוואה אובייקטיבית בין מודלים שונים וכיול של פרמטרים ארכיטקטוניים. בעבודה זו משתמשים בשלוש משפחות עיקריות של מדדים: יחס אות לרעש, שגיאה ממוצעת בריבוע, וחיזויים של איכות תפיסתית. יחס אות לרעש ((SNR)) מוגדר כיחס בין כוח האות המקורי לכוח הרעש הנותר לאחר עיבוד. בעיבוד אותות נמדד ביחידות דציבל ((dB)), כאשר הנוסחה הבסיסית היא:

$$(6.1) \quad \text{SNR} = 10 \log_{10} \frac{\sum_{n=1}^N |s_n|^2}{\sum_{n=1}^N |r_n - s_n|^2}$$

כאן s_n הוא האות המקורי, r_n הוא האות המשוחזר, וסכימה מתבצעת על כל הדגימות. עלייה ב-SNR תואמת לשיפור בעוצמת האות החזוי ביחס לשגיאה התיקיה. מדד זה רגיש במיוחד להטיות שיטתיות וכן למשרעת הרעש, מה שהופך אותו לשימושי להערכה של ביצועי מודל בתנאים רועשים. שגיאה ממוצעת בריבוע ((MSE)) מכמתת את ההפרש הממוצע בין הערכים החזויים למציאותיים, בריבוע, לאורך כל הרצף:

$$(6.2) \quad \text{MSE} = \frac{1}{N} \sum_{n=1}^N (s_n - r_n)^2$$

מדד זה מודגש כביטוי מתמטי של הפסד עיקרי בהדרכה של רשתות עצביות. ערך נמוך של MSE מעיד על התאמה הדוקה בין פלט הרשת למטרה. יתרון של MSE הוא קלות החישוב וניתנות לגזירה, דבר המאפשר בקרת מהלך ההדרכה בזמן בעבודות עתידיות. עם זאת, הוא אינו תמיד מתואם עם הערכה תפיסתית של איכות האות.

איכות תפיסתית של אות נמדדת בעזרת מדדים מתקדמים יותר, כולל שונות ספקטרלית והעוצמה הספקטרלית של הרעש השירי. מדדים אלו תופסים סוגיות של תפיסה שמיעתית אנושית שמדדים לינאריים מדדים לא ממשיים בצורה מספקת. בחקר זה, התמקדנו בעיקר ב-SNR וב-MSE כמו המדדים הראשוניים, כיוון שהם מספקים השוואה מהירה בשלב הפיתוח וניתן לחזור אליהם בעתיד עם מדדי תפיסה משוקללים כאשר משימות הזמן האמת מגבילות את דיוק ההדרכה.

יתרון של מערכות למידה עמוקה בקבלת מדדים כאלו טמון בכושרן ללמוד ייצוגים מרובי-סולם של הרעש הבלתי ידוע. בעוד שמסננים קלאסיים מסתמכים על הנחות של נתונים סטטיסטיים וספקטרום ידוע של רעש, רשתות עצביות LSTM יכולות להתאים הצגות פנימיות דינמיות בהתאם לתופעות של רעש מורכבות בעולם האמת [7].

6.2 השוואה בין עיבוד קלאסי לבין למידה עמוקה

השוואה בין שיטות מסורתיות לעיבוד אותות ואסטרטגיות למידה עמוקה היא קריטית להבנה של מקום כל שיטה בפיתוח בעולם האמת. שיטות קלאסיות המנותחות כאן כוללות סינון פס-חילוף ((band-pass filtering)), שיעור-בחירה בתחום התדר ((FFT peak-picking)) וניתוח ממונים ((wavelet denoising)).

סינון פס-חילוף בתחום התדר מאפשר הסרה של רכיבים בתדרים גבוהים, שהם לעתים קרובות המקום בו מרוכז חלק גדול מהרעש. עם זאת, שיטה זו דורשת ידע קודם של טווח התדרים של אות הסינוס, מה שמגביל את הגמישות שלה. בתחום של אות כללי לא ידוע קודם לכן, ניתן בקלות להחמיץ אות נוכח בתדרים בלתי צפויים או להסיר מידע שימושי אם פס-החילוף נקבע בשגיאה.

בחירת פסגות בתחום התדר ((FFT peak-picking)) מזהה את התדרים בעלי הכוח המרבי בספקטרום התדר. גישה זו יעילה בתנאים עם SNR גבוה, כיוון שפסגות אות אמיתיות בולטות בבירור. עם זאת, קיים מעבר קריטי: כאשר הרעש מתגבר, פסגות הרעש עלולות להתערבב עם פסגות אות אמיתיות, מה שמוביל לזיהוי שגוי ושגיאות גדולות בחיזוי תדר.

עיבוד ממונים מאפשר ניתוח רב-סולם של אות, שם ניתן לפרק את הרעש בטווחי סקאלה שונים וזיהוי רכיבי אות טוב יותר ברמות גבוהות של רעש. עם זאת, בחירת הממוני אם ופרמטרי הפירוק דורשת מומחיות ובניסיונים נרחבים.

מערכות למידה עמוקה, בהן בדגש על רשתות עצביות תוך-זמניות ((LSTM)), לומדות מייצוגים סמויים של הרעש ישירות מנתונים. על פי ממצאים אחרונים [12], בהשוואה לעיבוד קלאסי, מודלים של LSTM בדרך כלל משיגים שיפור משמעותי ב-SNR של 3–8 דציבל בתנאים של רעש גבוה ובמטבח וריאציות ספקטרום רעש. יתרון זה נובע מיכולתן של רשתות עצביות ללמוד קשרים לא-ליניאריים בין רצפי קלט-פלט בדרך שמסננים לינאריים לא יכולים להשיג.

מחיר ביצועים מוגברים של LSTM הוא גדלים חישוביים והצורך בנתוני הדרכה בעוצמה. בדרך כלל, מודל LSTM עם שכבות מרובות דורש מחשוב של מיליונים עד עשרות מיליונים של פעולות כפל-חיבור לכל רצף קלט, בעוד שמסנן פס-חילוף דורש מספר קטן בהרבה של פעולות. בהתאם, יישום בזמן אמת של מודלי LSTM עלול להימנע במקרים של כושר חישוב מוגבל, כגון התקנים מוטבעים או תרחישים כגון עיבוד על-יד.

בהקשר מודולי, מודלים כגון רשתות עצביות קונבולוציוניות עם ממד אחד ((1D CNN)) מציעים טעם של איזון בין פשטות חישובית ביצועים מוגברים. מודלים אלו דורשים פחות פרמטרים מאשר LSTM כולל מעבדים של כמה עשרות אלפי פרמטרים בלבד, ובמקרים מסוימים מפיקים תוצאות דומות לאלה של LSTM בנתונים סימולציוניים מוקדיים.

בהשלמה, במערכות חד-פעמיות או במקרים שבהם SNR כבר בעל ערך גבוה, שיטות קלאסיות עדיין יכולות להיות קו-בחירה מעשי מכיוון שהן פשוטות ליישום, ודורשות השקעה חישובית קטנה וכן כוח הסבר גבוה בהקשרים המדעיים והתעשייתיים. לעומת זאת, כאשר דיוק הוא בעדיפות ראשונה וכמות נתונים הדרכה מספקת זמינה, מודלים של למידה עמוקה מציעים יתרון משמעותי בביצועים שגובר ככל שמורכבות הרעש ללמד מיגמות אות לא ידועה עולה.

הקבלה בין השיטות מציעה הוא הקריטרי המעשיים שבהם להבחר קו-בחירה מתאים. בעבודות עתידיות, יתכן וניתן להשלב בחכמה אלמנטים של עיבוד קלאסי כתכונות קודמות חוקיות בתוך מודלי למידה עמוקה, תוך ניצול החוזקות של שתי הגישות בו זמנית.

ביבליוגרפיה

- [1] Tom B Brown et al. "Language Models are Few-Shot Learners." In: *Advances in Neural Information Processing Systems* 33 (2020).
- [2] Kevin Clark et al. "ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators." In: *International Conference on Learning Representations* (2020).
- [3] Jacob Devlin et al. "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding." In: *Proceedings of NAACL-HLT* (2019).
- [4] Jesse Engel et al. "Neural Audio Synthesis of Musical Notes with WaveNet Autoencoders." In: *Proceedings of the 34th International Conference on Machine Learning (ICML)*. 2017, pp. 1068–1077.
- [5] Yi Luo and Nima Mesgarani. "Conv-TasNet: Surpassing Ideal Time–Frequency Magnitude Masking for Speech Separation." In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 27.8 (2019), pp. 1256–1266.
- [6] Amir More, Reut Zmigrod, and Reut Tsarfaty. "Joint Transition-Based Models for Morpho-Syntactic Parsing: Parsing Strategies for MRLs and a Case Study from Modern Hebrew." In: *Transactions of the Association for Computational Linguistics* 7 (2019), pp. 33–48.
- [7] Eliya Nachmani, Yossi Adi, and Lior Wolf. "Voice Separation with an Unknown Number of Multiple Speakers." In: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. 2020, pp. 7164–7175.
- [8] Suyeon Park, Hyun-Suk Kim, and Inhwan Jang. "Hybrid CNN-LSTM Architectures for Sequence Modelling and Signal Separation." In: *arXiv preprint arXiv:2406.01234* (2024).
- [9] Alec Radford et al. "Language Models are Unsupervised Multitask Learners." In: *OpenAI Blog* 1 (2019).
- [10] Amit Seker et al. "AlephBERT: Language Model Pre-Training and Evaluation from Sub-Word to Sentence Level." In: *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2022, pp. 4152–4168.
- [11] Hugo Touvron et al. "LLaMA: Open and Efficient Foundation Language Models." In: *arXiv preprint arXiv:2302.13971* (2023).
- [12] Efthymios Tzinis, Shrikant Venkataramani, and Paris Smaragdis. "Improving Universal Sound Separation Using Sound Classification." In: *Proceedings of ICASSP*. 2020, pp. 696–700.

- [13] Cassia Valentini-Botinhao, Bryan Lim, and Evan Zisselman. “Speech Enhancement Using LSTM-Based Sequence-to-Sequence Models.” In: *Proc. Interspeech*. arXiv:1911.08616. 2019.
- [14] Ashish Vaswani et al. “Attention Is All You Need.” In: *Advances in Neural Information Processing Systems* 30 (2017).
- [15] Donald S Williamson, Yuxuan Wang, and DeLiang Wang. “Complex Ratio Masking for Monaural Speech Separation.” In: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 24.11 (2016), pp. 2236–2249.